FASE 0 — Presentación, Alineación y Viabilidad del Proyecto (Kickoff)

1. Título provisional del proyecto

Sistema Inteligente de Detección Automática de Noticias Falsas mediante Procesamiento de Lenguaje Natural y Machine Learning (PROVISIONAL)

2. Elevator Pitch

Desarrollar un modelo que pueda clasificar la veracidad de una noticia. Identificar si una noticia publicada por un medio es real o mal intencionada y solo busca generar clicks en su contenido. Este proyecto propone construir un sistema basado en Procesamiento de Lenguaje Natural (NLP) que clasifique automáticamente noticias como reales o fake. Aporta una aproximación técnica al problema de la desinformación usando técnicas de Big Data e IA.
Como resultado tendremos un mejor filtro para asegurarnos que las noticias que recibimos son de calidad.

3. El tema y el problema

Situación actual: Vivimos en la época del contenido, con grandes cantidades de noticias publicadas diariamente para captar la atención de usuarios. Las noticias falsas se difunden rápidamente en medios digitales y redes sociales, y la verificación manual no es escalable.
Impacto: Saturación de contenido no verificado, frustración del usuario y posible abandono de fuentes informativas.
Importancia: La información de calidad es fundamental para la sociedad. La desinformación puede generar pánico, desconfianza y visiones erróneas de la realidad.

4. Objetivo principal

Desarrollar un modelo de clasificación que permita detectar noticias falsas para tener un filtro fiable.

5. Alcance (IN / OUT)

IN	OUT
• Uso de dataset público de fake news • limpieza y procesamiento de texto • entrenamiento de modelo • evaluación con métricas • documentación	• Análisis de imágenes o videos • detección en tiempo real • análisis político específico • integración con APIs reales de redes sociales

6. Usuarios / Partes interesadas

Usuarios:
- Investigadores académicos
- estudiantes de datos
- periodistas
- usuarios interesados.

Deciden:
- Administradores del sistema
- Profesor

Beneficiados:
- Comunidad académica
- Plataformas digitales
- Desarrolladores

Afectados:
- Medios digitales
- autores de noticias mal clasificadas.

7. Propuesta de solución (alto nivel)

1. Recopilar noticias de redes sociales, datasets o bases de datos
2. Tratamiento de datos: limpieza y vectorización
3. Entrenamiento de modelo de IA para clasificar noticias verdaderas o falsas.

8. Datos (estimación inicial)

Fuentes: Redes sociales, medios digitales, otros modelos
Naturaleza: Públicos y privados
Riesgos: Medios digitales de pago
Tipo: Texto y datos tabulares.

9. Viabilidad técnica

Partes fáciles: Recopilación, limpieza y entrenamiento
Partes difíciles: Clasificación precisa, elección del modelo, tratamiento avanzado de datos e interpretabilidad
Tecnologías: Python, TensorFlow, Pandas, Power BI, modelos de clasificación.
Incertidumbres: Calidad de datasets, rendimiento y efectividad del modelo.

10. Riesgos y Plan B

Riesgos:

- Demasiado alcance
- baja eficiencia del modelo
- pipeline complejo
- textos ambiguos

Plan B:

- Reducir alcance al modelo baseline
- simplificar pipeline
- optimizar hiperparámetros
- usar dataset alternativo.

11. Reparto de tareas

Data: Ingesta, limpieza, EDA
Preprocesamiento: Vectorización, one-hot encoding
ML: Modelado y evaluación
Platform & BI: Dashboard, integración, monitorización.

12. Próximos pasos (7 días)

1. Crear repositorio Git
2. asignar roles
3. coordinar reuniones
4. buscar fuentes de noticias
5. tomar decisiones basadas en datos.

Acuerdo de trabajo

Canal: Discord / Teams
Disponibilidad: 10 horas semanales
Reuniones: 1 por semana (30–45 min)
Reglas:

- No subir nada a main sin PR.
- Todo trabajo tiene issue asignada.
- Documentar decisiones.

6. Respetar reparto y apoyar en bloqueos.

Repositorio inicial

IFP_PROYECTO_BIG_DATA – Publico de momento